

# Sztuczna inteligencja - lista 2

Mateusz Polito 266581

## 0. Informacje ogólne

Jako język programowania wybrałem Rust. Biblioteki użyte: Rand do losowych liczb

## 1. Implementacja gry Halma

Stan gry przechowywany jest w typie Board, który jest tablicą enumów Tile. Każdy Tile może mieć 3 stany: - pusty - gracz czarny (1) - gracz biały (2)

```
pub enum Tile {
    Empty,
    Black,
    White,
}

pub type Board = [[Tile; 16]; 16];
```

Oprócz samej planszy, aby opisać stan gry, stworzyłem enum GameState, który dodatkowo przechowuje informację o graczu, który doprowadził grę do danego stanu.

```
pub enum GameState {
    Start(Player),
    Moved(Player),
    Won(Player),
}
```

## 2. Generacja drzewa gry

Jako jeden węzeł drzewa gry stworzyłem strukturę DecisionTreeNode. Przechowuje ona aktualną planszę, opis stanu gry, listę powiązanych dzieci, oraz pomocniczą zmienną która opisuje, czy dzieci zostały już wygenerowane (optymalizacja dla minimax).

```
pub struct DecisionTreeNode {
    pub board: Board,
    pub game_state: GameState,
    pub children: Vec<DecisionTreeNode>,
    pub generated: bool,
}
```

Najważniejszą funkcją działającą na DecisionTreeNode jest funkcja generująca wszystkie możliwe ruchy dla danego stanu gry. Na początek sprawdza ona dla każdego koordynatu planszy, czy należy do ruszającego się gracza. Jeśli tak, to najpierw generuje ona wszystkie możliwe ruchy nie używające skoków, czyli przesuwania pionka o koordynaty opisane w liście pomocniczej DIRECTIONS. Ostatnim etapem jest wygenerowanie ruchów, które wymagają skoków, za pomocą funkcji generate\_valid\_jumps\_for\_point (widoczna poniżej w kodzie). Dodatkowo, jeżeli pionek znajduje się w obozie przeciwnika (lista koordynatów my\_winning\_coords), to zezwala ruchy tylko w obrębie tego obozu, zgodnie z zasadami Halma.

```
impl DecisionTreeNode {
    pub fn generate_children(&mut self, player_moving: Player) {
        self.generated = true;
        for y in 0..16 {
            for x in 0..16 {
                let from_coords = Coords { x, y };
                let my_winning_coords = match player_moving {
                    Player::Black => PLAYER_BLACK_WINNING,
                    Player::White => PLAYER_WHITE_WINNING,
                };
                //only move the current player's tiles
                if self.is_tile_mine(from_coords, player_moving) {
                    //check all 8 possible directions
                    for direction in DIRECTIONS.into_iter() {
                        let move_to = Coords {
                            x: x + direction.x,
                            y: y + direction.y,
```



```

        let jump_to_point = Coords {
            x: check_point.x + direction.x,
            y: check_point.y + direction.y,
        };
        if jump_to_point.is_in_board() {
            if self.is_tile_empty(jump_to_point) {
                if !jumps.contains(&jump_to_point) {
                    jumps.push(jump_to_point);
                    self.generate_valid_jumps_for_point(
                        jumps,
                        jump_to_point,
                        direction,
                    );
                }
            }
        }
    }
}

```

### 3. Implementacja minimax i alfa-beta cięcia

Funkcja `minimax` jest wywoływana z następującymi argumentami: - pierwszy węzeł drzewa decyzyjnego - maksymalna głębokość dla każdej iteracji funkcji wewnętrznej (używam 2) - heurystyka (funkcja implementująca cechę `Heuristic`) - opcjonalny limit rund po którym funkcja zewnętrzna zakończy działanie, inaczej działa do pierwszej wygranej - poziom logowania (nic, numer rundy, lub numer rundy wraz z informacją o wybranym ruchu) - pierwszy gracz

```

pub fn minimax(
    node: &mut DecisionTreeNode,
    max_depth: u32,
    heuristic: &mut impl Heuristic,
    rounds_limit: Option<u32>,
    log_level: LogLevel,
    mut player: Player
)

```

Następnie funkcja `minimax` wywołuje wewnętrzną rekurencyjną funkcję `minimax_inner`. Jedno takie wywołanie odpowiada jednej turze gry.

Funkcja wewnętrzna jest wywoływana dopóki nie zostanie osiągnięty limit rund, lub gdy zwróci węzeł drzewa mówiący o wygranej któregoś z graczy.

#### Budowa funkcji wewnętrznej `minimax_inner`:

Typ zwracany przez tą funkcję to enum `MinMaxResult`. Ma on 2 możliwe stany: - `Eval` - określa heurystyczną ewaluację stanu gry oraz indeks wybranego węzła w tablicy dzieci rodzica - `Leaf` - zwraca kopię wygrywającego węzła, oraz głębokość, na której została znaleziona (ponieważ oznacza to, ile rund musimy dodać)

```

enum MinMaxResult {
    Eval(f32, usize),
    Leaf(DecisionTreeNode, u32),
}

```

Teraz przejdę do działania funkcji:

Na początku sprawdzamy, czy osiągnęliśmy maksymalną głębokość rekurencyjnych wywołań. Jeżeli tak, zwracamy heurystyczną ewaluację stanu gry z perspektywy aktualnego gracza.

```

fn minimax_inner(
    node: &mut DecisionTreeNode,
    current_depth: u32,
    heuristic: &mut impl Heuristic,
    node_index: usize,

```

```

    maximizing: bool,
    player: Player,
) -> MinMaxResult {

    if current_depth == 0 {
        return MinMaxResult::Eval(heuristic.evaluate(&node.board, player), node_index);
    }

```

Potem zostaje wybrany gracz dla dzieci danego węzła

```

let next_player = match node.game_state {
    GameState::Start(player) => player,
    GameState::Moved(player) => player.other(),
    GameState::Won(_) => {
        return MinMaxResult::Leaf(node.clone(), current_depth);
    }
};

```

Następnie, ustawiam wartość maksymalizacji/minimalizacji tak, aby na pewno była mniejsza/większa od ewaluacji heurystyk.

```

let mut max_eval: f32 = match maximizing {
    true => f32::NEG_INFINITY,
    false => f32::INFINITY,
};

```

Jeżeli ten węzeł nie ma jeszcze wygenerowanych dzieci, to je generuję.

```

if !node.generated {
    node.generate_children(next_player);
}

```

Jeżeli węzeł po generacji nie ma dzieci, to poszło coś nie tak, a więc zatrzymuję program.

```

if node.children.len() == 0 {
    println!("Node with no children found! {}", &node);
    println!("Ensuring generation");
    node.generate_children(next_player);
    panic!("{}", &node);
}

```

Następnie wchodzę do pętli, która dla dzieci wywołuje rekurencyjnie funkcję `minmax_inner`, po czym wybiera stan gry z najlepszą oceną, lub zwraca dziecko z wygraną grą.

```

let mut max_child_index = 0;
let mut child_index = 0;

for mut child in &mut node.children {
    let minmax_inner_result = minmax_inner(
        &mut child,
        current_depth - 1,
        heuristic,
        child_index,
        !maximizing,
        player,
    );
    match minmax_inner_result {
        MinMaxResult::Eval(child_eval, _) => match maximizing {
            false => {
                if max_eval > child_eval {
                    max_eval = child_eval;
                    max_child_index = child_index;
                }
            }
            true => {
                if max_eval < child_eval {
                    max_eval = child_eval;

```

```

        max_child_index = child_index;
    }
}
},
MinMaxResult::Leaf(_, _) => return minmax_inner_result,
}

child_index += 1;
}

return MinMaxResult::Eval(max_eval, max_child_index);

```

## Alfa-beta - różnice względem minimax

Dodatkowe parametry alfa i beta w funkcji wewnętrznej:

```

fn alfa_beta_inner(
    node: &mut DecisionTreeNode,
    current_depth: u32,
    heuristic: &mut impl Heuristic,
    node_index: usize,
    maximizing: bool,
    mut alfa: f32,
    mut beta: f32,
    player: Player,
) -> MinMaxResult

```

Sprawdzanie parametrów w pętli wybierającej dzieci, potencjalne przerwanie jeśli  $\beta \leq \alpha$

```

for mut child in &mut node.children {
    let minmax_inner_result = alfa_beta_inner(
        &mut child,
        current_depth - 1,
        heuristic,
        child_index,
        !maximizing,
        alfa,
        beta,
        player,
    );
    match minmax_inner_result {
        MinMaxResult::Eval(child_eval, _) => match maximizing {
            false => {
                if max_eval > child_eval {
                    max_eval = child_eval;
                    max_child_index = child_index;
                }
                if beta > child_eval {
                    beta = child_eval;
                }
            }
            true => {
                if max_eval < child_eval {
                    max_eval = child_eval;
                    max_child_index = child_index;
                }
                if alfa < child_eval {
                    alfa = child_eval;
                }
            }
        }
    },
    MinMaxResult::Leaf(_, _) => return minmax_inner_result,
}

```

```

    }

    if beta <= alfa {
        break;
    }
    child_index += 1;
}

```

## 4. Heurystyki

Wszystkie heurystyki muszą spełniać cechę `Heuristic`, która zawiera jedną metodę `evaluate`

```

pub trait Heuristic {
    fn evaluate(&mut self, board: &Board, evaluating_player: Player) -> f32;
}

```

### Heurystyka losowa

Zwraca losową liczbę między -100 a 100.

```

pub struct HeuristicRandom {
    pub rng: ThreadRng,
}

impl Heuristic for HeuristicRandom {
    fn evaluate(&mut self, _board: &Board, _evaluating_player: Player) -> f32 {
        return self.rng.gen_range(-100.0..100.0);
    }
}

```

### Heurystyka na podstawie bliskości do rogu przeciwnika

Dla każdego gracza zdefiniowałem 2 tablice 16x16, gdzie do każdego pola przypisałem wartość odległości Manhattan do bazy przeciwnika.

Następnie patrzę, gdzie stoją pionki danego gracza, i sumuję punkty dla tych pozycji.

Wynik mnożę przez stałą, dla dopasowania do pozostałych heurystyk.

```

pub struct HeuristicProximity {
    pub power: f32,
}

impl Heuristic for HeuristicProximity {
    fn evaluate(&mut self, board: &Board, evaluating_player: Player) -> f32 {
        let mut score: f32 = 0.;
        //let mut score = 0.;
        match evaluating_player {
            Player::Black => {
                for y in 0..16 {
                    for x in 0..16 {
                        let tile = index_board(board, Coords { x, y });
                        if matches!(tile, Tile::Black) {
                            score += PLAYER_BLACK_HEURISTIC_PROXIMITY[y as usize][x as usize];
                        }
                    }
                }
            }
            Player::White => {
                for y in 0..16 {
                    for x in 0..16 {
                        let tile = index_board(board, Coords { x, y });
                        if matches!(tile, Tile::White) {
                            score += PLAYER_WHITE_HEURISTIC_PROXIMITY[y as usize][x as usize];
                        }
                    }
                }
            }
        }
    }
}

```

```

    }
  }
}
return (score * self.power).clamp(-100.0, 100.0);
}
}

```

### Heurystyka na podstawie bliskości do rogu przeciwnika promująca pionek przodujący

Poprzednią heurystykę zmodyfikowałem, dając większą wagę dla najlepszego z pionków, i mniejszą dla pozostałych.

```

pub struct HeuristicProximityWithSingle {
    pub single_power: f32,
    pub multi_power: f32,
}

```

Różnice w kodzie w stosunku do HeuristicProximity:

Przechowywanie maksymalnej wartości pionka:

```
let mut max: f32 = f32::NEG_INFINITY;
```

W pętli ustawianie największej wartości:

```

if tile_ev > max {
    max = tile_ev;
}

```

Dodanie ważonej maksymalnej wartości pionka do wyniku:

```
score = score * self.multi_power + max * self.single_power;
```

## 5. Wyniki

### Minimax przy głębokości 1

Zapętla się w nieskończoność :(

### Minimax przy głębokości 2

Heurystyka	Czas	Liczba rund
Losowa	41.99s	21211
Odległość	1.52s	262
Odległość +	1.33s	206

### Alfa-beta przy głębokości 1

Heurystyka	Czas	Liczba rund
Losowa	0.37s	13816
Odległość	0.01s	262
Odległość +	0.01s	206

### Alfa-beta przy głębokości 2

Heurystyka	Czas	Liczba rund
Losowa	30.49s	13843
Odległość	0.83s	261
Odległość +	0.69s	205

## 6. Wnioski

Widać wyraźnie, że przycinanie alfa-beta dużo przyspiesza algorytm.

Wyniki przy głębokości 1 są takie same jak przy 2, jednak dużo szybsze. Jednak przy zastosowaniu dwóch różnych heurystyk dla różnych graczy mogłyby się tam uwidocznic większe różnice. Ogólnie moja implementacja algorytmu jest szybka, jednak zużywa dużo pamięci RAM, przez co nie jestem w stanie przeprowadzić analizy dla głębokości 3.

Mam kilka pomysłów na zoptymalizowanie ilości użytej pamięci, jednak nie starczyło mi czasu na ich implementację.